

Stima di $R(t)$ con il metodo Monte Carlo – Metropolis

Materiale di studio generato per approfondire i fondamenti teorici

Esame MSN — Modellazione e Simulazioni Numeriche

Samuel Seligardi & Claude Code

A.A. 2025/2026

Indice

1	Contesto e motivazione	2
2	Il numero di riproduzione: dall'equazione di rinnovo	2
2.1	L'equazione di Lotka–Euler	2
2.2	Riscrittura con la base	3
3	La distribuzione dei tempi di generazione $\phi(s)$	3
3.1	Significato biologico	3
3.2	La distribuzione Gamma continua	3
3.3	Discretizzazione	4
3.4	Valori numerici attesi	4
4	Il modello statistico: distribuzione di Poisson	5
4.1	Motivazione	5
5	La funzione di verosimiglianza e il massimo di verosimiglianza	5
5.1	Log-verosimiglianza	5
5.2	Massimo di verosimiglianza (MLE)	6
5.3	Perché non usare direttamente l'MLE?	6
6	Approccio Bayesiano: la distribuzione posteriore	7
6.1	Notazione: $\pi(\cdot)$ come densità di probabilità	7
6.2	Il framework Bayesiano: tre ingredienti	7
6.3	Prior uniforme e prior improprio	8
6.4	La distribuzione posteriore esplicita	8
7	L'algoritmo Metropolis	9
7.1	Principio generale: catene di Markov Monte Carlo	9
7.2	L'algoritmo passo per passo	9

7.3	Interpretazione fisica del log-ratio	10
8	Garanzia teorica: bilancio dettagliato e convergenza	11
8.1	Il problema: costruire W data Π	11
8.2	Il bilancio dettagliato come condizione sufficiente	11
8.3	Derivazione della probabilità di accettazione: $F(z) = \min(1, z)$	12
8.4	Velocità di convergenza	14
9	Indipendenza delle stime giornaliere	14
10	Cancellazione della scala	15
10.1	Il problema della sorgente dati	15
10.2	Dimostrazione della cancellazione	15
10.3	Differenza statistica	15
11	Post-processing: media mobile causale	16
12	Il ritardo strutturale: confronto con il dato INFN	16
13	Confronto sistematico con il Metodo 1 (SIR)	17
14	Riepilogo completo	17

1 Contesto e motivazione

Il **numero di riproduzione effettivo** $R(t)$ è la quantità epidemiologica centrale per monitorare un'epidemia: rappresenta il numero medio di nuovi infetti generati da un singolo caso infettivo nel giorno t , tenendo conto delle misure di contenimento e dell'immunità parziale della popolazione.

- $R(t) > 1$: l'epidemia è in crescita (ogni caso genera in media più di un secondario)
- $R(t) = 1$: l'epidemia è stazionaria
- $R(t) < 1$: l'epidemia è in regressione

Il Metodo 1 (SIR) stima $R(t)$ tramite la formula approssimata $R(t) \approx 1 + T_R \cdot \Delta I/I$, che dipende dal parametro $T_R = 1/\gamma$ e introduce un ritardo strutturale di circa una settimana.

Il **Metodo 2** (implementato dalla metodologia ISS/FBK, Merler 2020) usa un approccio completamente diverso:

1. modella esplicitamente la *distribuzione dei tempi di generazione* $\phi(s)$;
2. usa un modello statistico Poisson per i nuovi contagi;
3. stima $R(t)$ tramite un algoritmo Metropolis applicato *indipendentemente* per ogni giorno.

Vantaggi principali rispetto al Metodo 1:

- non richiede la conoscenza di γ (o T_R);
- fornisce una stima che anticipa il dato INFN di circa una settimana;
- è più accurato (errore massimo 0.20–0.27 vs 0.2–0.6 del SIR).

2 Il numero di riproduzione: dall'equazione di rinnovo

2.1 L'equazione di Lotka–Euler

Il punto di partenza del Metodo 2 è l'equazione di rinnovo (nota anche come *equazione di Lotka–Euler* in demografia):

$$C(t) = R(t) \sum_{s=1}^{\infty} \phi(s) C(t-s) \quad (1)$$

dove:

- $C(t)$ = nuovi casi (sintomatici) al giorno t ;
- $\phi(s)$ = probabilità che un contagio avvenga s giorni dopo l'infezione del caso primario (*distribuzione del tempo di generazione*);
- $R(t)$ = numero di riproduzione al giorno t , la quantità da stimare.

Osservazione

L'equazione (1) non è un'approssimazione: è la definizione operativa di $R(t)$ nel contesto dei modelli a rinnovo (renewal models). Il modello SIR ne è un caso speciale con $\phi(s) = \gamma e^{-\gamma s}$ (distribuzione esponenziale con parametro γ).

2.2 Riscrittura con la base

Per un giorno t fissato, il termine $\sum_s \phi(s) C(t-s)$ è una costante nota (dipende solo dalla storia passata, non da $R(t)$). Lo chiamiamo **base**:

$$\lambda_{\text{base}}(t) = \sum_{s=1}^{S_{\max}} \phi(s) C(t-s) \quad (2)$$

dove il troncamento a $S_{\max} = 25$ giorni è giustificato perché $\phi(s) < 2 \times 10^{-3}$ per $s > 25$ (si veda la Sezione 3).

L'equazione di rinnovo (1) diventa allora:

$$\boxed{\lambda(t) = R(t) \cdot \lambda_{\text{base}}(t)} \quad (3)$$

dove $\lambda(t)$ è il *numero atteso* di nuovi casi al giorno t .

3 La distribuzione dei tempi di generazione $\phi(s)$

3.1 Significato biologico

Il **tempo di generazione** X è la variabile aleatoria che misura il ritardo, in giorni, tra il momento in cui un individuo viene infettato e il momento in cui infetta a sua volta un caso secondario. Non è direttamente osservabile: si stima indirettamente dall'analisi di cluster di casi con coppie infettante–infettato tracciate.

La distribuzione $\phi(s) = P(X = s)$ (discreta, definita su $s = 1, 2, 3, \dots$) è cruciale perché determina quanta “memoria storica” entra nel calcolo di $\lambda(t)$: un ϕ con coda lunga significa che casi molto vecchi contribuiscono ancora alla trasmissione odierna.

3.2 La distribuzione Gamma continua

Guzzetta e Merler (7 dicembre 2020) stimano per COVID-19 in Italia che il tempo di generazione *continuo* X segue una distribuzione Gamma:

$$X \sim \text{Gamma}(\alpha, \theta) \quad \alpha = 1.87, \quad \theta = \frac{1}{\beta} = \frac{1}{0.28} \approx 3.57 \text{ giorni} \quad (4)$$

con densità di probabilità:

$$f(x; \alpha, \theta) = \frac{x^{\alpha-1} e^{-x/\theta}}{\Gamma(\alpha) \theta^\alpha}, \quad x > 0 \quad (5)$$

dove $\Gamma(\alpha) = \int_0^\infty t^{\alpha-1} e^{-t} dt$ è la **funzione Gamma di Eulero** (non la distribuzione Gamma: attenzione alla notazione sovraccarica).

I momenti della distribuzione Gamma sono:

$$\mathbb{E}[X] = \alpha\theta \approx 1.87 \times 3.57 \approx 6.68 \text{ giorni} \quad (6)$$

$$\text{Var}[X] = \alpha\theta^2 \approx 1.87 \times 12.74 \approx 23.8 \text{ giorni}^2 \quad (7)$$

$$\sigma_X = \sqrt{\text{Var}[X]} \approx 4.88 \text{ giorni} \quad (8)$$

La distribuzione è **asimmetrica a destra** (il coefficiente di asimmetria vale $2/\sqrt{\alpha} \approx 1.46$): la maggior parte dei contagi avviene entro 5–10 giorni, con una coda che si estende fino a 20–25 giorni. Questo è tipico dei processi biologici: esistono casi rari di trasmissione tardiva (contatti prolungati, casi gravi con lunga infettività).

Perché la Gamma?

La distribuzione Gamma è la scelta naturale per modellare tempi positivi con asimmetria a destra. È inoltre la somma di α variabili esponenziali indipendenti con parametro β (per α intero), il che le conferisce una interpretazione biologica: il processo di trasmissione può avvenire in α “stadi” successivi. Per $\alpha = 1$ si riduce all’esponenziale (il caso del modello SIR compartimentale).

3.3 Discretizzazione

Il modello lavora con **giorni interi**, ma X è continua. La probabilità discreta $\phi(s)$ si ottiene integrando f sull’intervallo unitario centrato in s :

$$\phi(s) = P\left(s - \frac{1}{2} \leq X \leq s + \frac{1}{2}\right) = \int_{s-1/2}^{s+1/2} f(u; \alpha, \theta) du, \quad s = 1, 2, \dots \quad (9)$$

Questa è la discretizzazione di *midpoint binning*: ogni valore intero cattura l’intera probabilità dell’intervallo unitario centrato su di esso. È il metodo corretto per discretizzare una densità continua (a differenza di campionare $f(s)$ puntualmente, che non dà una distribuzione di probabilità).

Troncamento: per $s > 25$, il contributo $\phi(s)$ è trascurabile. Si verifica che $\sum_{s=26}^\infty \phi(s) \approx 5.2 \times 10^{-3}$, cioè lo 0.52% della probabilità totale. Si pone quindi $S_{\max} = 25$ e si **rinormalizza**:

$$\phi(s) \leftarrow \frac{\phi(s)}{\sum_{k=1}^{25} \phi(k)}, \quad s = 1, \dots, 25 \quad (10)$$

affinché il vettore $(\phi(1), \dots, \phi(25))$ sia una distribuzione di probabilità discreta.

3.4 Valori numerici attesi

s (giorni)	1	2	3	4	5	6	7	8	...
$\phi(s)$ (approx.)	0.073	0.103	0.111	0.108	0.099	0.088	0.076	0.064	...

La media $\sum_s s \phi(s) \approx 6.65$ giorni deve coincidere con la media teorica della Gamma (a meno dell'errore di troncamento). Questa è la prima verifica di correttezza da eseguire in MATLAB.

4 Il modello statistico: distribuzione di Poisson

4.1 Motivazione

Dato $R(t)$ e la storia passata $C(t-1), \dots, C(t-25)$, il numero di nuovi casi $C(t)$ è una variabile aleatoria. Il modello adottato è:

$$C(t) \mid R(t) \sim \text{Poisson}(\lambda(t)) = \text{Poisson}(R(t) \cdot \lambda_{\text{base}}(t)) \quad (11)$$

La distribuzione di Poisson è giustificata da due argomenti:

1. **Argomento del processo puntuale:** in ogni istante, un individuo infettivo ha una piccola probabilità di trasmettere il virus. Se i contatti sono indipendenti e la probabilità di trasmissione è piccola ma il numero di individui suscettibili è grande, il numero di trasmissioni segue una Poisson (*legge dei grandi numeri per processi di Bernoulli rari*).
2. **Argomento della superspreading:** anche in presenza di eterogeneità (alcuni individui trasmettono molto di più di altri), il conteggio aggregato giornaliero si approssima bene con una Poisson per grandi popolazioni.

La probabilità di massa della Poisson è:

$$P(C(t) = c \mid R(t)) = \frac{e^{-\lambda(t)} \lambda(t)^c}{c!}, \quad c = 0, 1, 2, \dots \quad (12)$$

Osservazione

La Poisson ha un solo parametro λ che funge sia da media che da varianza: $\mathbb{E}[C] = \text{Var}[C] = \lambda$. Ne consegue che la deviazione standard relativa è $\sigma_C / \mathbb{E}[C] = 1/\sqrt{\lambda}$: la stima di $R(t)$ sarà tanto più precisa quanto più grande è $\lambda(t)$, ossia quanto più casi ci sono.

5 La funzione di verosimiglianza e il massimo di verosimiglianza

5.1 Log-verosimiglianza

Per un giorno t fissato, con $\lambda_{\text{base}}(t)$ nota, vogliamo stimare $R(t)$ dall'osservazione di $C(t) = c$. La **funzione di verosimiglianza** è:

$$L(R) = P(C(t) = c \mid R) = \frac{e^{-R\lambda_{\text{base}}} (R\lambda_{\text{base}})^c}{c!} \quad (13)$$

dove, per brevità, scriviamo $\lambda_{\text{base}} = \lambda_{\text{base}}(t)$.

La **log-verosimiglianza** è:

$$\begin{aligned}\ell(R) &= \log L(R) = -R\lambda_{\text{base}} + c \log(R\lambda_{\text{base}}) - \log(c!) \\ &= c \log R + c \log \lambda_{\text{base}} - R\lambda_{\text{base}} - \log(c!)\end{aligned}\tag{14}$$

I termini $c \log \lambda_{\text{base}}$ e $-\log(c!)$ sono costanti rispetto a R : non influenzano la posizione del massimo.

5.2 Massimo di verosimiglianza (MLE)

Deriviamo $\ell(R)$ rispetto a R e uguagliamo a zero:

$$\frac{d}{dR} \ell(R) = \frac{c}{R} - \lambda_{\text{base}} = 0\tag{15}$$

da cui:

$$\boxed{R_{\text{MLE}} = \frac{c}{\lambda_{\text{base}}} = \frac{C(t)}{\lambda_{\text{base}}(t)}}\tag{16}$$

Per verificare che sia un massimo (e non un minimo), calcoliamo la derivata seconda:

$$\frac{d^2}{dR^2} \ell(R) = -\frac{c}{R^2} < 0 \quad \text{per } R > 0, c > 0\tag{17}$$

Poiché la derivata seconda è strettamente negativa, $\ell(R)$ è **strettamente concava** su $R > 0$, e R_{MLE} è l'unico massimo globale.

Osservazione

Il risultato $R_{\text{MLE}} = C(t)/\lambda_{\text{base}}(t)$ ha un'interpretazione intuitiva diretta: $R(t)$ è il rapporto tra i casi osservati oggi e il numero di casi atteso se $R(t) = 1$.

5.3 Perché non usare direttamente l'MLE?

L'MLE è la stima puntuale ottimale per c grande (caso asintotico). Per c piccolo, la distribuzione di Poisson è fortemente asimmetrica, e la *media della distribuzione a posteriori* è preferibile al massimo per due motivi.

Nota di notazione (anticipazione): nella Sezione 6 verrà introdotta formalmente la **distribuzione a posteriori** $\pi(R | c)$, ovvero la densità di probabilità per il parametro R dopo aver osservato il dato c . Qui la lettera π (con argomento) non è la costante $\pi \approx 3.14\dots$, ma la notazione statistica standard per una densità di probabilità; il simbolo “ $| c$ ” si legge “dato c ” (condizionato all'osservazione c).

1. **Asimmetria:** quando c è piccolo, la distribuzione posteriore $\pi(R | c) \propto e^{\ell(R)}$ è asimmetrica a destra. La media è spostata verso valori più alti rispetto all'MLE (il massimo). Usare la media riduce l'errore quadratico medio (*bias-variance tradeoff*).

2. **Quantificazione dell'incertezza:** il campionamento Metropolis produce naturalmente una distribuzione di campioni da $\pi(R | c)$, permettendo di calcolare intervalli di confidenza senza ipotesi aggiuntive.

Per $c \rightarrow \infty$, la Poisson converge a una Gaussiana e la media coincide con il massimo: $\mathbb{E}_\pi[R | c] \rightarrow R_{\text{MLE}}$ (per il Teorema del Limite Centrale).

6 Approccio Bayesiano: la distribuzione posteriore

6.1 Notazione: $\pi(\cdot)$ come densità di probabilità

Disambiguazione: $\pi(\cdot)$ non è la costante 3.14...

In questo documento — e in quasi tutta la letteratura statistica — la lettera π con un argomento (come $\pi_0(R)$ o $\pi(R | c)$) indica una **funzione di densità di probabilità**. Questo uso è completamente distinto dalla costante matematica $\pi \approx 3.14159 \dots$. Quando scriviamo $\pi(R | c)$ intendiamo: “la densità di probabilità della variabile aleatoria R , condizionata all’osservazione c ”. L’argomento a sinistra della barra verticale è la variabile; quello a destra è il dato su cui condizioniamo.

6.2 Il framework Bayesiano: tre ingredienti

Nell’approccio **frequentista** usato finora per l’MLE, il parametro $R(t)$ è trattato come una costante ignota: si cerca il valore che massimizza $L(R)$.

Nell’approccio **Bayesiano**, invece, il parametro ignoto $R(t)$ è trattato come una *variabile aleatoria*: se ne descrive la distribuzione di probabilità, che viene aggiornata man mano che si osservano i dati. I tre ingredienti sono:

1. **Distribuzione a priori** (*prior*): $\pi_0(R)$.
È la densità di probabilità per $R(t)$ *prima* di osservare il dato $C(t) = c$. Codifica la conoscenza (o l’ignoranza) iniziale sul parametro. Il pedice 0 distingue il prior dalla distribuzione aggiornata.
2. **Verosimiglianza**: $L(R) = P(C(t) = c | R)$.
Già calcolata nella Sezione 5: misura la compatibilità tra il valore del parametro R e il dato osservato c . È una funzione di R , *non* una probabilità per R .
3. **Distribuzione a posteriori** (*posterior*): $\pi(R | c)$.
È la densità di probabilità per $R(t)$ *dopo* aver osservato c . Combina l’informazione del prior con quella contenuta nel dato. È l’oggetto che Metropolis camperà.

Il legame tra le tre componenti è il **Teorema di Bayes**:

$$\pi(R | c) = \frac{L(R) \cdot \pi_0(R)}{\int_0^\infty L(R') \cdot \pi_0(R') dR'} \quad (18)$$

Il denominatore $Z = \int_0^\infty L(R') \pi_0(R') dR'$ è la **costante di normalizzazione** (chiamata anche *evidenza*): è un numero reale positivo che dipende solo dal dato c e garantisce che

$\int_0^\infty \pi(R | c) dR = 1$. Poiché Z è una costante rispetto a R , si può scrivere in forma proporzionale:

$$\pi(R | c) \propto L(R) \cdot \pi_0(R) \quad (19)$$

Questa forma è sufficiente per l'algoritmo Metropolis, che non ha mai bisogno di calcolare Z esplicitamente (vedi Sezione 7).

6.3 Prior uniforme e prior improprio

Adottiamo un **prior uniforme** su $R > 0$:

$$\pi_0(R) \propto 1, \quad R > 0 \quad (20)$$

Questo prior esprime la *completa assenza di informazione a priori*: nessun valore di $R(t)$ è considerato più plausibile degli altri prima di guardare i dati.

Il termine **improprio** (*improper prior*) indica che questo prior non è una vera distribuzione di probabilità nel senso classico, perché $\int_0^\infty 1 dR = +\infty$: non è normalizzabile a 1. I prior impropri sono comunque accettati in statistica Bayesiana a condizione che la distribuzione a posteriori risultante sia *propria* (abbia integrale finito). Verifichiamo questa condizione nel paragrafo successivo.

6.4 La distribuzione posteriore esplicita

Sostituendo $\pi_0(R) \propto 1$ nella (19):

$$\pi(R | c) \propto L(R) \cdot 1 = L(R) \quad (21)$$

Con prior uniforme, la posteriore *coincide con la verosimiglianza* (a meno della costante di normalizzazione). Sostituendo la forma esplicita di $L(R)$:

$$\pi(R | c) \propto R^c e^{-R\lambda_{\text{base}}}, \quad R > 0 \quad (22)$$

Questo è esattamente il nucleo di una distribuzione **Gamma**: $R | c \sim \text{Gamma}(c + 1, 1/\lambda_{\text{base}})$.

L'integrale $\int_0^\infty R^c e^{-R\lambda_{\text{base}}} dR = \Gamma(c + 1)/\lambda_{\text{base}}^{c+1}$ è finito per ogni $c \geq 0$, confermando che la posteriore è propria (nonostante il prior fosse improprio).

La **media posteriore** (stimatore ottimo sotto perdita quadratica, detto *stimatore di Bayes*) è:

$$\mathbb{E}[R | c] = \frac{c + 1}{\lambda_{\text{base}}} \quad (23)$$

mentre la **moda** della posteriore (che con prior uniforme coincide con l'MLE) è c/λ_{base} . La differenza $+1/\lambda_{\text{base}}$ è trascurabile per $c \gg 1$ ma significativa per c piccolo.

Osservazione

In linea di principio, per questa distribuzione posteriore (Gamma) la stima esatta potrebbe essere calcolata analiticamente senza Metropolis. Il Metropolis è usato nella

metodologia ISS perché il modello reale include correlazioni tra giorni diversi e prior non uniformi che rendono la distribuzione posteriore intractable analiticamente. Nella nostra implementazione semplificata (stima giorno per giorno indipendente), il Metropolis approssima correttamente la Gamma posteriore.

7 L'algoritmo Metropolis

7.1 Principio generale: catene di Markov Monte Carlo

L'algoritmo **Metropolis** (Metropolis et al., 1953) è il capostipite dei metodi MCMC (Markov Chain Monte Carlo). Il problema che risolve è:

Definizione

Sia $\mathcal{X}$ lo spazio dei valori ammissibili per il parametro di interesse (nel nostro caso $\mathcal{X} = \mathbb{R}_{>0}$, i reali positivi, poiché $R > 0$). Sia $\pi : \mathcal{X} \rightarrow \mathbb{R}_{\geq 0}$ una *distribuzione target* — la distribuzione da cui vogliamo campionare — di cui si conosce solo la forma funzionale, non la costante di normalizzazione.

Il problema è costruire una **catena di Markov** $\{X^{(0)}, X^{(1)}, \dots, X^{(N)}\}$ su $\mathcal{X}$, ovvero una successione di valori tali che $X^{(k)}$ dipende dal passato solo tramite $X^{(k-1)}$, la cui **distribuzione stazionaria** sia π . Con “distribuzione stazionaria” si intende che, per k sufficientemente grande, la distribuzione di $X^{(k)}$ converge a π indipendentemente dal punto di partenza $X^{(0)}$.

Nel nostro contesto: la distribuzione target π è la **distribuzione a posteriori** $\pi(R | c)$ introdotta nella Sezione 6, ovvero:

$$\pi(R) \propto e^{\ell(R)} = e^{c \log R - R \lambda_{\text{base}}} = R^c e^{-R \lambda_{\text{base}}} \quad (24)$$

(scriviamo $\pi(R)$ per brevità, con c e λ_{base} fissi per il giorno t corrente). La costante di normalizzazione $\int_0^\infty R^c e^{-R \lambda_{\text{base}}} dR$ non viene mai calcolata: Metropolis la evita interamente, come si vede dal passo (b) qui sotto.

7.2 L'algoritmo passo per passo

Inizializzazione: $R^{(0)} = 1.0$ (soglia epidemica, valore neutro).

Passo k ($k = 1, 2, \dots, N_{\text{iter}}$):

a) **Proposta.** Si campiona un candidato:

$$R^* = R^{(k-1)} + U(-\delta, +\delta), \quad \delta = 1.5 \quad (25)$$

dove $U(-\delta, +\delta)$ è una variabile uniforme sull'intervallo $(-\delta, +\delta)$. La distribuzione di proposta è **simmetrica**: $q(R^* | R) = q(R | R^*)$, proprietà essenziale per Metropolis (non sarebbe necessaria per Metropolis–Hastings, che è la versione più generale).

b) **Log-ratio.** Se $R^* > 0$, si calcola:

$$\begin{aligned}\log \rho &= \ell(R^*) - \ell(R^{(k-1)}) \\ &= [c \log(R^* \lambda_{\text{base}}) - R^* \lambda_{\text{base}}] - [c \log(R^{(k-1)} \lambda_{\text{base}}) - R^{(k-1)} \lambda_{\text{base}}] \\ &= c \log \frac{R^*}{R^{(k-1)}} - \lambda_{\text{base}}(R^* - R^{(k-1)})\end{aligned}\quad (26)$$

Il termine $c \log \lambda_{\text{base}}$ è presente sia in $\ell(R^*)$ che in $\ell(R^{(k-1)})$ e si cancella esattamente. Questo significa che λ_{base} entra nel log-ratio solo attraverso il termine lineare $-\lambda_{\text{base}}(R^* - R^{(k-1)})$.

c) **Accettazione/rifiuto.** Si pone:

$$R^{(k)} = \begin{cases} R^{(k-1)} & \text{se } R^* \leq 0 \text{ (rifiuto forzato)} \\ R^* & \text{se } \log \rho \geq 0 \text{ (accettazione certa)} \\ R^* \text{ con prob. } e^{\log \rho} & \text{se } \log \rho < 0 \\ R^{(k-1)} & \text{altrimenti (rifiuto)} \end{cases}\quad (27)$$

In pratica: si genera $u \sim U(0, 1)$ e si accetta se $\log u < \log \rho$ (equivalente a $u < e^{\log \rho}$, ma numericamente più stabile per evitare overflow di e^x per $\log \rho$ molto negativo).

Burn-in: i primi $N_{\text{burnin}} = 500$ valori sono scartati. Durante il burn-in la catena “si avvicina” alla zona di alta probabilità a partire dal punto iniziale $R = 1$ (che potrebbe essere lontano dalla moda della posteriore).

Stima finale:

$$\hat{R}(t) = \frac{1}{N_{\text{iter}} - N_{\text{burnin}}} \sum_{k=N_{\text{burnin}}+1}^{N_{\text{iter}}} R^{(k)} = \frac{1}{4500} \sum_{k=501}^{5000} R^{(k)}\quad (28)$$

7.3 Interpretazione fisica del log-ratio

La formula (26) ha un’interpretazione intuitiva chiara. Separando i due termini:

Termine	Segno tipico	Effetto sulla catena
$c \log(R^*/R^{(k-1)})$	> 0 se $R^* > R$	Spinge verso R più alto se ci sono casi
$-\lambda_{\text{base}}(R^* - R^{(k-1)})$	< 0 se $R^* > R$	Frena l’aumento proporzionalmente a λ_{base}
Bilancio	0	Equilibrio in $R^* = R_{\text{MLE}} = c/\lambda_{\text{base}}$

In $R = R_{\text{MLE}} = c/\lambda_{\text{base}}$, il log-ratio per qualsiasi spostamento ϵ è:

$$\log \rho = c \log \frac{R_{\text{MLE}} + \epsilon}{R_{\text{MLE}}} - \lambda_{\text{base}} \epsilon \approx c \frac{\epsilon}{R_{\text{MLE}}} - \lambda_{\text{base}} \epsilon = \epsilon \left(\frac{c}{R_{\text{MLE}}} - \lambda_{\text{base}} \right) = 0\quad (29)$$

confermando che l’MLE è il punto stazionario.

8 Garanzia teorica: bilancio dettagliato e convergenza

8.1 Il problema: costruire W data Π

L'algoritmo Metropolis nasce come soluzione a un problema generale che condivide la stessa logica dei processi di Markov discreti. Si vuole calcolare il **valore di aspettazione** di una funzione f rispetto a una distribuzione target Π :

$$\langle f(X) \rangle = \sum_i f(X_i) \Pi_i \quad (30)$$

dove la somma è su tutte le possibili configurazioni X_i , pesata dalla distribuzione di probabilità Π .

Si costruisce a tal fine una **catena di Markov** con matrice di transizione W , i cui elementi $W_{ij} = P(i \leftarrow j)$ sono probabilità di transizione dallo stato j allo stato i . Valgono le proprietà $W_{ij} \geq 0$ e $\sum_i W_{ij} = 1$ per ogni j .

Iterando a partire da una distribuzione iniziale P_0 , la distribuzione dopo N passi è $P^{(N)} = W^N P_0$. Se vale la condizione di **stazionarietà** $W\Pi = \Pi$ (ovvero Π è l'autovettore di W con autovalore 1), allora per ergodicità:

$$P^{(N)} = W^N P_0 \xrightarrow{N \rightarrow \infty} \Pi \quad (31)$$

indipendentemente dal punto di partenza P_0 . Grazie a questo, possiamo **sostituire medie temporali** sull'evoluzione asintotica della catena con **medie su Π** : questo è il principio fondamentale di tutti i metodi MCMC.

Problema fondamentale di MCMC

Data la distribuzione target Π (di cui si conosce la forma funzionale, non la costante di normalizzazione), come si costruisce una matrice di transizione W tale che $W\Pi = \Pi$?

Una **condizione sufficiente** (non necessaria) per soddisfare $W\Pi = \Pi$ è il bilancio dettagliato, derivato nel paragrafo seguente.

8.2 Il bilancio dettagliato come condizione sufficiente

La ragione per cui l'algoritmo Metropolis funziona è la soddisfazione della condizione di **bilancio dettagliato** (detailed balance). Questa condizione garantisce che la distribuzione target π è una distribuzione stazionaria della catena di Markov.

Definizione: bilancio dettagliato

Una catena di Markov con probabilità di transizione $T(x \rightarrow y)$ soddisfa il bilancio dettagliato rispetto a π se:

$$\pi(x) T(x \rightarrow y) = \pi(y) T(y \rightarrow x) \quad \forall x, y \in \mathcal{X} \quad (32)$$

Per Metropolis, la probabilità di transizione (per proposta simmetrica) è:

$$T(R \rightarrow R^*) = q(R^* | R) \cdot \alpha(R, R^*) = q(R^* | R) \cdot \min\left(1, \frac{\pi(R^*)}{\pi(R)}\right) \quad (33)$$

dove i due fattori corrispondono alle due fasi sequenziali dell'algoritmo:

- $q(R^* | R)$: **probabilità di proposta** — con quale probabilità l'algoritmo estrae R^* come candidato, dato che si trova in R . Nel nostro caso è la distribuzione uniforme $U(R - \delta, R + \delta)$: non dipende da π e non sa nulla della distribuzione target.
- $\alpha(R, R^*)$: **probabilità di accettazione** — dato che R^* è stato proposto, con quale probabilità viene accettato. Questa dipende da π : vale 1 se R^* è più probabile del corrente, meno di 1 altrimenti.

Il prodotto $q \cdot \alpha$ è la probabilità che entrambe le fasi abbiano successo, ovvero che la catena si sposti effettivamente da R a R^* .

Verifica del bilancio dettagliato. Poiché q è simmetrica ($q(R^* | R) = q(R | R^*)$), dividiamo per q e verifichiamo:

$$\pi(R) \cdot \min\left(1, \frac{\pi(R^*)}{\pi(R)}\right) = \pi(R^*) \cdot \min\left(1, \frac{\pi(R)}{\pi(R^*)}\right) \quad (34)$$

Caso 1: $\pi(R^*) \geq \pi(R)$.

$$\begin{aligned} \text{Lato sinistro} &= \pi(R) \cdot \frac{\pi(R^*)}{\pi(R)} = \pi(R^*) \\ \text{Lato destro} &= \pi(R^*) \cdot 1 = \pi(R^*) \quad \checkmark \end{aligned}$$

Caso 2: $\pi(R^*) < \pi(R)$ (simmetrico per scambio di R e R^*). $\checkmark$

Il bilancio dettagliato implica che π è una distribuzione stazionaria. Affinché sia anche l'unica (condizione di *ergodicità*), è sufficiente che la catena sia:

- **irriducibile**: da qualsiasi punto si può raggiungere qualsiasi regione con probabilità positiva (garantito dalla proposta uniforme con $\delta = 1.5$, che copre un intervallo ampio intorno al valore corrente);
- **aperiodica**: non ci sono cicli deterministici (garantito dal fatto che ci sono proposte che vengono rifiutate, quindi la catena può rimanere ferma).

8.3 Derivazione della probabilità di accettazione: $F(z) = \min(1, z)$

Si fattorizza la probabilità di transizione in due contributi:

$$W_{ij} = P_{ij}^{(0)} \cdot a_{ij} \quad (35)$$

dove $P_{ij}^{(0)}$ è la **probabilità di proporre** la mossa $j \rightarrow i$ e $a_{ij} \in [0, 1]$ è la **probabilità di accettare** la proposta.

Sostituendo nella condizione di bilancio dettagliato $W_{ij}\Pi_j = W_{ji}\Pi_i$:

$$P_{ij}^{(0)} a_{ij} \Pi_j = P_{ji}^{(0)} a_{ji} \Pi_i \quad (36)$$

da cui si ottiene il rapporto tra le probabilità di accettazione:

$$\frac{a_{ij}}{a_{ji}} = \frac{P_{ji}^{(0)} \Pi_i}{P_{ij}^{(0)} \Pi_j} \quad (37)$$

Proposta simmetrica. Se $P_{ij}^{(0)} = P_{ji}^{(0)}$ (come la distribuzione $U(-\delta, +\delta)$ del nostro algoritmo), i termini di proposta si cancellano:

$$\frac{a_{ij}}{a_{ji}} = \frac{\Pi_i}{\Pi_j} \quad (38)$$

Si cerca dunque una funzione $F : [0, +\infty) \rightarrow [0, 1]$ tale che, posto $z = \Pi_i/\Pi_j$:

$$a_{ij} = F(z), \quad a_{ji} = F(z^{-1}), \quad \text{con vincolo } \frac{F(z)}{F(z^{-1})} = z \quad (39)$$

La soluzione più semplice alla (39) è:

$$\boxed{F(z) = \min(1, z)} \quad (40)$$

Verifica diretta:

- $z > 1$: $F(z) = 1$, $F(z^{-1}) = z^{-1}$; $F(z)/F(z^{-1}) = z$ ✓
- $z < 1$: $F(z) = z$, $F(z^{-1}) = 1$; $F(z)/F(z^{-1}) = z$ ✓
- $z = 1$: $F(z) = F(z^{-1}) = 1$; $F(z)/F(z^{-1}) = 1 = z$ ✓

L'algoritmo Metropolis risultante è dunque:

1. Proponi la mossa $j \rightarrow i$ con distribuzione simmetrica
2. Calcola $z = \Pi_i/\Pi_j$
3. Accetta con probabilità $\min(1, z)$:
 - se $\Pi_i \geq \Pi_j$: accetta sempre (stato proposto più probabile)
 - se $\Pi_i < \Pi_j$: accetta con probabilità $\Pi_i/\Pi_j < 1$

Intuitivamente: le mosse verso stati più probabili sono sempre accettate; quelle verso stati meno probabili sono accettate tanto meno quanto più la probabilità dello stato proposto è inferiore a quella dello stato corrente.

Osservazione

Nel caso continuo del nostro algoritmo, $z = \pi(R^*)/\pi(R^{(k-1)}) = e^{\log \rho}$ (con $\log \rho$ definito dalla (26)). La condizione di accettazione $\log u < \log \rho$ è equivalente a $u < e^{\log \rho} = z$, ovvero $u < \min(1, z)$: esattamente la regola $F(z) = \min(1, z)$ derivata qui sopra.

8.4 Velocità di convergenza

La velocità con cui la catena converge alla distribuzione stazionaria dipende dall'**autocorrelazione della catena**, quantificata dal *tempo di mescolamento*. Con una proposta uniforme di ampiezza $\delta = 1.5$:

- Se δ è troppo piccola: alta accettazione, ma la catena si muove lentamente (esplorazione inefficiente).
- Se δ è troppo grande: bassa accettazione (molte proposte finiscono in zone di bassa probabilità), movimenti rari ma grandi.
- Il valore ottimale per una target Gaussiana è $\delta \approx 2.38\sigma$ (regola di Gelman et al., 1996), che porta a un tasso di accettazione del 44%.

Con $\delta = 1.5$ e $R(t)$ tipicamente in $[0.5, 3]$, ci si aspetta un tasso di accettazione nell'intervallo 20–50% (da verificare empiricamente).

9 Indipendenza delle stime giornaliere

Un aspetto fondamentale del Metodo 2 è che la stima di $R(t)$ per ciascun giorno t è **completamente indipendente** dalle stime degli altri giorni. Per ogni t :

1. Si fissa $c = C(t)$ (osservazione del giorno t).
2. Si calcola $\lambda_{\text{base}}(t)$ dalla storia passata $C(t-1), \dots, C(t-25)$.
3. Si esegue una catena Metropolis di 5000 passi per campionare $\pi(R | c)$.
4. Si stima $R(t)$ come media della catena post burn-in.

La storia passata entra nella stima *solo* attraverso $\lambda_{\text{base}}(t)$, che viene trattata come una costante per l'ottimizzazione del giorno t . Questo è molto diverso da metodi come il filtro di Kalman o il smoothing per serie temporali, in cui la stima di $R(t)$ dipende anche dall'informazione del futuro.

Conseguenza pratica: il calcolo è parallelizzabile – si potrebbero eseguire le $n - S_{\text{max}}$ catene Metropolis in parallelo su $n - S_{\text{max}}$ core separati.

10 Cancellazione della scala

10.1 Il problema della sorgente dati

La metodologia ISS originale utilizza i *casi sintomatici* $S(t)$ (file non disponibile pubblicamente come CSV scaricabile). Il codice usa invece **nuovi_positivi** DPC, denotato $C_{\text{DPC}}(t)$.

I due dataset differiscono per un fattore di scala (approssimativamente costante):

$$C_{\text{DPC}}(t) \approx k \cdot S(t), \quad k > 1 \quad (41)$$

Il fattore $k > 1$ riflette il fatto che i nuovi positivi includono anche i pre-sintomatici e gli asintomatici diagnosticati tramite contact tracing.

10.2 Dimostrazione della cancellazione

Calcoliamo la base per i dati DPC:

$$\lambda_{\text{base}}^{\text{DPC}}(t) = \sum_{s=1}^{25} \phi(s) C_{\text{DPC}}(t-s) = \sum_{s=1}^{25} \phi(s) k S(t-s) = k \sum_{s=1}^{25} \phi(s) S(t-s) = k \cdot \lambda_{\text{base}}^{\text{ISS}}(t) \quad (42)$$

Il fattore k moltiplica sia il numeratore che il denominatore dell'MLE:

$$R_{\text{MLE}}^{\text{DPC}} = \frac{C_{\text{DPC}}(t)}{\lambda_{\text{base}}^{\text{DPC}}(t)} = \frac{k S(t)}{k \lambda_{\text{base}}^{\text{ISS}}(t)} = \frac{S(t)}{\lambda_{\text{base}}^{\text{ISS}}(t)} = R_{\text{MLE}}^{\text{ISS}} \quad (43)$$

Il fattore di scala si cancella esattamente nel rapporto. La stima di $R(t)$ è identica per le due sorgenti dati (a parità di modello statistico). $\square$

10.3 Differenza statistica

La varianza dell'MLE Poisson è:

$$\text{Var}[R_{\text{MLE}}] \approx \frac{R(t)}{\lambda_{\text{base}}(t)} = \frac{R(t)^2}{C(t)} \quad (44)$$

(approssimazione di Cramér–Rao). Poiché $C_{\text{DPC}} = k S$, i dati DPC producono $\lambda_{\text{base}}^{\text{DPC}} = k \lambda_{\text{base}}^{\text{ISS}}$ e quindi:

$$\text{Var}[R_{\text{MLE}}^{\text{DPC}}] = \frac{R(t)}{k \lambda_{\text{base}}^{\text{ISS}}(t)} = \frac{1}{k} \text{Var}[R_{\text{MLE}}^{\text{ISS}}] \quad (45)$$

Usare i dati DPC (più numerosi per il fattore $k > 1$) produce **intervalli di confidenza più stretti**: un vantaggio inatteso della sostituzione.

11 Post-processing: media mobile causale

La stima $\widehat{R}(t)$ grezza presenta ancora oscillazioni per due motivi:

1. **Rumore osservativo:** le segnalazioni epidemiologiche hanno forti oscillazioni settimanali (meno tamponi nel weekend, aggiornamenti batch il lunedì). Questo rumore entra in $C(t)$ e quindi in $\widehat{R}(t)$.
2. **Fluttuazioni Monte Carlo:** la catena Metropolis di 4500 passi ha una varianza residua piccola ($\sigma \approx 3 \times 10^{-3}$, trascurabile rispetto al rumore osservativo).

Si applica una **media mobile causale a 7 giorni**:

$$R_{\text{MC}}(t) = \frac{1}{7} \sum_{k=0}^6 \widehat{R}(t-k) = \frac{\widehat{R}(t) + \widehat{R}(t-1) + \dots + \widehat{R}(t-6)}{7} \quad (46)$$

Il termine **causale** (o *one-sided*) significa che la finestra guarda solo al passato e al presente: non vengono mai usati valori futuri $\widehat{R}(t+1), \dots$. In un sistema di sorveglianza in tempo reale, i dati del futuro non sono disponibili; la scelta causale è quindi l'unica fisicamente sensata.

Il periodo di 7 giorni è scelto per attenuare il ciclo settimanale delle segnalazioni (periodo di 7 giorni): la media mobile elimina esattamente le componenti periodiche il cui periodo divide la finestra.

12 Il ritardo strutturale: confronto con il dato INFN

I dati ufficiali INFN/CovidStat usano la **data di inizio sintomi** (stimata tramite un modello di nowcasting). Il Metodo 2 usa la data di referto DPC, sistematicamente più tardiva di circa 5–10 giorni.

Paradossalmente, il Metodo 2 produce una stima di $R(t)$ che **anticipa** il dato INFN di circa una settimana. Il motivo è sottile:

- Il dato INFN al giorno t include anche le *correzioni retroattive* dei giorni precedenti (i casi con data di inizio sintomi nel passato ma segnalati con ritardo). Questo introduce un ritardo di pubblicazione di circa una settimana.
- Il Metodo 2 usa i casi *così come appaiono nel database DPC* al giorno t , senza aspettare correzioni retroattive. La stima è quindi più tempestiva e, poiché $\lambda_{\text{base}}(t)$ dipende solo dai casi passati rispetto a t , non subisce aggiornamenti retroattivi.

13 Confronto sistematico con il Metodo 1 (SIR)

Aspetto	Metodo 1 — SIR	Metodo 2 — Metropolis
Modello	Deterministico (formula approssimata)	Probabilistico (Poisson)
Dipendenza da γ	Esplicita: $R \approx 1 + T_R \Delta I / I$	Assente
Dist. tempi generazione	Implicita (finestra fissa T_R)	Esplicita: Gamma($\alpha=1.87$, $\theta=3.57$)
Ritardo vs INFN	+1 settimana (data referto > data sintomi)	−1 settimana (anticipo)
Errore max vs INFN	0.2–0.6	0.20–0.27
Sensibilità al rumore	Alta (senza pre-smoothing)	Moderata (distribuita su 25 giorni)
Costo computazionale	Basso (formula algebrica)	Alto (~ 5 min su MATLAB)
Funziona senza T_R	No	Sì

14 Riepilogo completo

Pipeline del Metodo 2

Input: $C(1), C(2), \dots, C(n)$ [nuovi_positivi DPC]

$\phi(s)$ $s = 1, \dots, 25$ [Gamma(1.87, 3.57), discretizzata, normalizzata]

Per ogni $t = 26, 27, \dots, n$:

$$\lambda_{\text{base}}(t) = \sum_{s=1}^{25} \phi(s) C(t-s)$$

Catena Metropolis, $N_{\text{iter}} = 5000$, $N_{\text{burnin}} = 500$, $\delta = 1.5$:

target: $\pi(R) \propto \exp[C(t) \log R - R \lambda_{\text{base}}(t)]$

$$\hat{R}(t) = \frac{1}{4500} \sum_{k=501}^{5000} R^{(k)}$$

Post-processing:

$$R_{\text{MC}}(t) = \frac{1}{7} \sum_{k=0}^6 \hat{R}(t-k) \quad [\text{media mobile causale 7 giorni}]$$